

TSAD Agent 项目报告

学 号	2023010685
姓 名	田铠瑄
班 级	无 37

1 论文阅读

1.1 ReAct

问题：ReAct[1] 想解决的是“只推理”和“只行动”各自的不足。只让模型写思维链时，它只能依赖内部知识，容易产生幻觉；只让模型调用工具时，它又可能缺少计划和工作记忆，不知道为什么要做下一步。

流程：ReAct 的核心就是不断循环 Thought--Action--Observation。模型先用 Thought 分析当前情况，再用 Action 调用搜索、网页操作等工具，环境返回 Observation，模型根据新信息继续思考，直到给出答案。在这个过程中，语言模型负责决策，外部工具负责提供真实信息，而完整的交互记录相当于工作记忆。论文在问答、事实核查、文字游戏和网页购物任务上做了实验，结果说明推理和行动结合后通常比单独行动更好，也能减少一部分事实幻觉。

思考：我觉得 ReAct 更多是在解决一个工程组织问题。它没有提出新的模型结构或科学理论，只是整理了一套通用流程。不过，这个简单的框架后来被大量 Agent 工作采用，大概说明好的工程抽象本身也很有价值。

1.2 TAMA

问题：TAMA[2] 关注如何使用 MLLM 完成 TSAD 任务。传统方法往往需要针对数据集训练模型或调整参数，而普通 LLM 又不擅长直接理解大量数字。因此，TAMA 把时间序列画成图像，让模型像人一样从曲线形状中寻找异常，并进一步给出异常类型和文字解释。

流程：TAMA 的整体流程可以分为以下几步：

1. 对序列做 z-score 标准化，再用重叠的滑动窗口切分，并把每个窗口画成折线图。
2. 在多模态参考学习中，先给模型看几张正常序列图，让它总结正常模式。
3. 在多模态分析中，模型检测查询图里的异常区间，输出异常类型、置信度和解释。
4. 在多尺度自反思中，把已经发现的异常区域放大后再次检查。
5. 最后把各个窗口中的局部坐标换成全局坐标，对置信度求和、对异常类型投票，再通过阈值得到最终结果。

实验结果：图像输入整体上比文本输入表现更好，正常参考和放大复检也能提高稳定性。不过，模型对图像旋转很敏感，而且 seasonal 异常的分类准确率只有 29%，说明它并不是对所有异常都同样擅长。

个人认为 TAMA 工作还存在几个问题：

- ◇ 论文把多变量序列直接按通道拆开处理，但有些异常正是由变量之间的关系变化造成的。这样强行解耦虽然方便，却可能丢掉重要信息，我认为并不合理。
- ◇ z-score 使用整条序列的均值和方差，所以更适合离线检测。在线场景中未来数据还没有出现，而且异常本身也可能改变方差。
- ◇ 固定窗口也不一定能同时适应单点异常、短期形态异常和长期趋势异常，我认为可以考虑真正的多尺度窗口，并在复现中引入了这一点并证明了有效性。
- ◇ 因为大模型是可以识别色彩的，而我认为直接把时间序列绘制为折线图的操作，几乎没有利用任何丰富的色彩通道可能包含的信息。我认为可以通过色彩来表达数值幅度，或者用三个色彩通道来表达三个（甚至多个）不同变量的信息，从而高效利用彩色图像的表达能力和大模型处理彩色图像的能力。
- ◇ 系统通过大模型直接从图像中输出数字坐标，我认为其定位精度大概率存在问题，复现实验时也证明了这一点缺陷。
- ◇ 图像旋转实验的结果表现很差，我感觉可能是由于模型受到 position embedding 的影响，或许可以通过调整位置嵌入的策略来解决。
- ◇ TAMA 实际上需要正常参考图。对于 Dodgers、NormA 这类没有训练集的数据，正常片段是怎样在不查看测试标签的情况下选出来的，这一点不太理解。在我的复现中，我通过数值分析来选取一些可能正常的片段作为参考，并引导大模型不要完全信任。
- ◇ 自反思只会放大第一轮已经检出的区域，因此不能找回第一轮漏掉的异常，复现实验时发现这个问题导致 recall 指标比较低。此外，趋势和周期异常只看局部也可能失去背景。
- ◇ 后处理中直接累加置信度还会受到窗口覆盖次数影响，我认为应该除以覆盖次数后再比较。

1.3 HMA-TSAD

问题：HMA-TSAD[3] 是在 TAMA 基础上继续解决长时间序列的分析问题。TAMA 的处理流程基本固定，而普通 ReAct 在交互轮数很多时容易遗忘、重复或者产生幻觉。因此，本工作把全局规划和具体执行拆成了两个层次。

流程：Planner 负责观察当前状态，包括已经画过哪些区间、覆盖率、历史子任务和对应摘要，然后安排下一项任务。Executor 按照 ReAct 的方式执行任务，可以调用 Plot、Compare、Mark 和 Finish 工具。Plot 和 Compare 会触发多模态模型分析图像，任务完成后再由 Summarizer 压缩本轮过程，把摘要交回 Planner。这样就能不断进行“规划、执行、总结、再规划”，同时避免把所有历史内容都塞进上下文。论文还设计了结果、覆盖率和重复度三个分数来筛选较好的 Agent 轨迹，用这些数据训练轻量 Planner。

思考：这个分层结构很适合长序列，但也带来了更多模型调用，成本和随机性都会增加，小规模复现实验就消耗了大量 token（目前大概 100 元?）。此外，论文对很多细节的描述还是很模糊，个人认为并不能支持完全准确复现原版工作，在我的复现中对很多细节补充了自己的理解或者修正。

1.4 论文关系

整体来看，ReAct 教 MLLM Agent 怎样边想边做，TAMA 教它怎样看时间序列，HMA-TSAD 则教它面对长序列时怎样安排工作。

ReAct 提供了 Thought–Action–Observation 的通用循环；TAMA 把时间序列画成图，并提供了正常参考、异常分析和局部复检的具体方法；HMA-TSAD 再把 ReAct 用作 Executor，同时加入 Planner、全局状态和任务摘要，解决长序列中的任务安排和上下文管理问题。

2 系统设计与实现

2.1 数据处理与图像生成

为了减小极端值对标准化的影响，我没有直接使用全局 z-score，而是使用中位数和 MAD 做稳健标准化（AI 启发）。画图时会保留每一段中的最大值和最小值，避免降采样时刚好把尖峰异常丢掉；横轴则一直使用原序列坐标，方便把模型给出的局部结果换回全局区间。

正常参考优先从训练数据中选取。如果没有训练数据，就根据变化程度从测试序列中无监督地找一些可能正常的片段，并提示模型这些参考可能被异常污染，不完全可信。这里不会使用标签，防止数据泄露（TAMA 关于这一点没有明确说明其如何处理）。

2.2 Planner、Executor 与状态记录

Planner 看到的是一个压缩后的全局状态，其中包括序列长度、已经观察的区间、覆盖率、异常候选和历史子任务摘要。它每轮只安排一个目标，例如先看全局概览、放大某个候选，或者检查还没有覆盖的区域。这样可以避免把很长的工具调用记录全部放进上下文。

Executor 按照 ReAct 的方式完成这个目标。它会在 Thought 中说明判断，再从以下工具中选择 Action:

- ◇ **Plot:** 画出指定区间，并让多模态模型寻找异常候选;
- ◇ **Compare:** 把待检查片段和正常参考并排画出，判断差异是否足够明显;
- ◇ **Mark:** 记录异常起止位置、类型、置信度和证据;
- ◇ **Finish:** 结束当前子任务。

每个子任务结束后，Summarizer 会把目标、操作和主要发现压缩成一小段文字，再交回 Planner。系统同时用 JSONL 保存每次模型请求、工具调用和状态变化，方便检查 Agent 为什么得到某个结果。

2.3 模型调用与结果输出

MLLM 通过 API 调用，图像会被编码后和固定的 JSON 输出格式一起发送。当 Planner 完成分析或达到最大步数后，程序会合并相邻或重叠的异常标记，生成最终的异常区间，并保存置信度、异常类型和证据。预测文件生成以后，评估程序会读取标签并计算指标。

3 系统改进

针对每一版代码的存在的问题和之前读论文时的感受，我对系统总共进行了 5 次迭代，以下把最初版和五次升级版分别称为 v0-v5。

3.1 增加反思

v0 存在的问题: v0 基本按照论文流程运行，模型看到可疑区域后就可以直接 Mark。这样比较依赖模型第一次看图的判断，可能出现坐标较粗、证据不足和重复观察的问题。论文中也没有给出一套很具体的最终复检方法。

改进：v1 增加了证据检查和 reflection。Mark 前需要确认异常区间与图像分析候选有重叠，并达到置信度阈值；Planner 也会优先让强候选和正常参考比较。主流程结束后，系统会把候选附近放大，再让模型决定保留、删除或调整区间。如果 Executor 漏掉了已经被分析器发现的高置信候选，reflection 也可以把它补回来。最后再合并相邻标记，减少重复结果。这部分是我在复现论文基础上加入的第一层改进。

3.2 正常参考与证据约束

v1 存在的问题：v1 虽然会选择正常参考，但只是把几个数值上较平稳的片段交给模型，没有形成明确的“正常模式”。在没有训练集时，参考片段还可能本身就含有异常。另外，全局概览图中的坐标比较粗，不适合直接作为最终结果。

改进：v2 先根据安全元数据或自相关估计周期（AI 启发），再综合幅度、粗糙度、斜率和形状距离选择多个参考。模型会总结正常形态，并给每个参考记录可靠程度和可能的污染。检测时又把观察分成 overview 和 detail：概览图只负责找候选，只有放大后的 detail 证据才能用于 Mark。reflection 图里还会用红色区域标出当前候选，让模型更清楚地判断边界。这一版主要解决 v1 中正常参考怎样合理选取和图像坐标不够准两个问题。

3.3 真正多尺度分析

v2 存在的问题：v2 的分析窗口主要按三个周期设置，但我认为同一个尺度很难同时看清单点异常、周期形态变化和较长的趋势漂移，应该加入不同尺度的参考来定位不同类型的异常或精确定位异常。

改进：v3 建立了单周期、三周期和五周期，三种尺度的窗口及正常参考。单周期窗口主要看局部尖峰，三周期窗口用来比较周期形态，五周期窗口则保留更长的趋势背景。Compare 会在多个尺度上分别比较，并根据差异和参考可靠性选择更合适的结果，而不是把同一张图简单放大几次。这也对应了我在 TAMA 阅读中对固定窗口的反思。

3.4 注意力管理和边界修正

v3 存在的问题：v3 的 Agent 有时会反复查看最明显的区域，却没有继续检查其他候选和未覆盖部分，这会降低 recall。模型直接从图上读坐标时，异常边界也容易偏移，而且一个宽图中可能还有没有处理的第二个异常。

改进：v4 记录每次 Plot 和 Compare 的关注区间，拦截完全重复或高度重叠的操作，并维护未处理候选、已排除候选和最大未覆盖区间三个队列。Planner 会先处理已

有候选，再转向最大的覆盖空缺；一个异常被标记后也只关闭它附近的小范围，不会把整张图都当作已经解决。对只靠覆盖搜索发现的低置信候选，要求至少两次独立观察。坐标方面，系统会结合局部斜率和粗糙度变化做数值边界修正（AI 启发），再与模型给出的区间一起保存。这一版解决了模型反复观察，导致漏检或 token 浪费，以及坐标不准的问题。

3.5 长序列分片处理

v4 存在的问题：虽然 v4 在 UCR 上表现已经很好，但是在长序列上的表现又明显下降了。因为 v4 仍然让一个 Agent 处理整条序列。序列太长时，压缩后的图像可能把短异常缩成几个像素，变得难以识别；Agent 的状态和调用次数也会变多。

改进：模仿 TAMA 的思路，系统先把长序列切成连续窗口，每个窗口独立运行 v4 的整体流程，再把局部坐标加上窗口起点，映射回原序列；窗口还可以设置重叠比例，避免异常刚好被切在边界上。

合并结果时，系统在每个时间点统计覆盖它的窗口。每个窗口给出该点的最高异常置信度，没有检出异常时记为 0，再用置信度求和得到投票分数。超过阈值的连续点会被合成异常区间，并保留支持窗口、代表性证据和异常类型。虽然我在一开始阅读 TAMA 时提出其覆盖次数导致置信度虚高的问题，但是实际实验发现确实还是论文的求和方法比我之前认为的求平均方法更好用，后者导致很多异常因为平均置信度太低而被抑制。

4 实验结果汇总及分析

4.1 评价指标

实验使用 Precision (P)、Recall (R) 和 F1 评价检测结果。。由于时间序列异常既要判断有没有检测到，也要判断区间是否准确，因此我从下面四个角度计算指标：

- ◇ **Point：**把每个时间点分别看作正常或异常，直接统计点级别的 TP、FP 和 FN。
- ◇ **Point-adjusted：**只要预测区间碰到一个真实异常区间，就把该真实区间内的点都看作检出。这个指标更关注有没有发现异常事件，但可能弱化边界不准的问题。
- ◇ **Range：**把连续异常区间看作一个事件。预测区间与任意真实区间相交就算正确预测，真实区间被任意预测区间碰到就算成功召回。

◇ **Overlap:** Recall 是每个真实区间被预测覆盖的平均比例, Precision 是每个预测区间真正落在异常范围内的平均比例, 由二者计算 F1, 更直接地反映边界是否准确。

每个样本先独立计算以上 12 个指标, 再对同一数据集中的样本取算术平均, 得到表中的宏平均结果。UCR 部分包 4 个样本; SMAP 包含 54 个样本。方便起见, v0-v4 只在 UCR 上测试, v5 在 UCR 和 SMAP 上测试。

4.2 结果汇总

表 1: 各版本实验结果的宏平均 (P 、 R 、 $F1$)

数据集	版本	Point			Point-adjusted			Range			Overlap		
		P	R	F1	P	R	F1	P	R	F1	P	R	F1
UCR	v0	0.124	0.073	0.092	0.355	0.500	0.415	0.375	0.500	0.417	0.213	0.073	0.099
UCR	v1	0.933	0.515	0.585	0.938	1.000	0.964	1.000	1.000	1.000	0.933	0.515	0.585
UCR	v2	0.661	0.806	0.643	0.681	1.000	0.764	1.000	1.000	1.000	0.661	0.806	0.643
UCR	v3	0.743	0.807	0.743	0.765	1.000	0.852	1.000	1.000	1.000	0.743	0.807	0.743
UCR	v4	0.628	0.941	0.734	0.644	1.000	0.760	0.750	1.000	0.833	0.650	0.941	0.749
UCR	v5	0.638	0.941	0.739	0.655	1.000	0.768	0.750	1.000	0.833	0.650	0.941	0.749
SMAP	v5	0.493	0.148	0.182	0.611	0.689	0.625	0.493	0.651	0.534	0.479	0.139	0.167

4.3 结果分析

从 v0 到 v1 的提升最明显。加入证据检查和 reflection 后, UCR 的 Point F1 从 0.092 提高到 0.585, Range F1 从 0.417 提高到 1.000, 说明系统从经常找错位置变成了能够稳定碰到真实异常。不过, v1 的 Point Recall 只有 0.515, 而 Point-adjusted 和 Range 已经很高, 说明当时找到的区间仍然偏窄, 不能只看调整后的指标。

v2 更重视正常参考和异常边界, Point Recall 提高到 0.806, 但 Point Precision 从 0.933 降到 0.661, 表现为找得更全, 同时预测范围也更宽。v3 加入多尺度分析后, Point Precision 和 Recall 分别为 0.743 和 0.807, Point F1 达到 0.743, 是 UCR 各版本中最平衡的一版, 说明不同尺度对短异常和较长形态异常确实有帮助。

v4 和 v5 的 Point Recall 都达到 0.941, Overlap F1 也提高到 0.749, 说明覆盖搜索和边界修正减少了漏检。但两版的 Range Precision 都只有 0.750, 表明额外搜索也带来了一些误报。理论上, v5 和 v4 在 UCR 数据集上的表现应当完全一致, 目前存在的区别是由于 MLLM 本身存在随机性导致的。此外, v4 和 v5 关注的是覆盖率和长序列检

测能力的提升，所以无法在短序列且每个序列只有一处异常的 UCR 数据集上充分展现出优势，指标结果看起来还不如 v3，这很正常。

SMAP 上的实验结果说明系统能碰到一部分异常事件，却经常只覆盖其中很短的一段，或者漏掉持续时间较长、形态不明显的异常。后续如果继续改进，可以着重提高长异常的完整覆盖，并减少分片中产生的误报。

整体上来看，v5 版复现的指标和 HMA-TSAD 原论文报告的指标基本一致。

5 案例分析

以下选取三个典型行为案例，来分析系统的功能和优劣。

5.1 UCR 136：短序列简单异常的最优效果

UCR 136 长度为 5900，真实异常区间是 [1598, 1708]。v5 最终预测为 [1596, 1711]，Point Precision、Recall 和 F1 分别为 0.957、1.000 和 0.978，Range F1 为 1.000。图 1 可以看到两个区间几乎完全重合。





图 1: UCR 136 的真实异常与最终预测。红色为真实区间，蓝色为预测区间，重叠部分呈紫色。


表 2: UCR 136 的关键 Agent 轨迹

阶段	Planner 计划	Observation、状态变化与结果
正常模式学习	查看 1、3、3、5 个周期的四张训练参考图	得到周期约为 182 的稳定正常模式：每个周期只有一个平滑、宽而单峰的峰值，roughness 约为 0.030–0.033，长期趋势接近 0。四个参考的可靠度为 0.98–0.99，给后续判断提供了基准。
全局概览	Plot(0, 5899) → Finish	概览图发现 [1552, 1565] 附近出现压缩在一起的多个尖峰，局部频率约为正常值的 3 到 4 倍；其余周期都比较稳定。

阶段	Planner 计划	Observation、状态变化与结果
局部放大	Plot [1285, 1830]	细节图说明概览坐标过窄：真正异常不是 13 个点，而是大约 [1600, 1685] 的连续 ripple burst。该段 roughness 明显升高，并用十几个小峰替代了一个正常周期。
参考比较 与标记	Compare 3P ref2 → Mark	Compare 在 [1369, 1914] 中同时看到了异常及其前后的正常周期，并与训练参考 [703, 1248] 对照。模型将边界修正为 [1582, 1698]，类型为 shapelet，置信度 0.94。
覆盖搜索	继续执行四次 coverage 子任务	Agent 分别检查 [3634, 4179]、[4767, 5312]、[2501, 3046] 和 [369, 914]，均判断为正常；对过宽的 [1915, 3633] 请求被拦截。这部分没有增加误报，细节覆盖率最终为 0.477。
Reflection 与数值修 正 评估	对候选附近 [1114, 2166] 再次 复检 标签仅在预测完 成后读取	Reflection 汇总来自 Plot 和 Compare 的两个独立候选，确认异常是连续的高频小波动。随后的 roughness 边界修正把最终区间调整为 [1596, 1711]。真实区间为 [1598, 1708]，预测多覆盖 5 个正常点且没有漏掉异常点。



(a) *Compare* 将测试片段与 3P 正常参考并排比较，高频小波动与正常单峰周期的差异非常明显。



(b) *Reflection* 对候选区间进行最后确认，红色区域覆盖了完整的异常片段。

图 2: UCR 136 的 Agent 轨迹中关键的 *Compare* 和 *Reflection* 图像。

分析：该样本的正常模式非常稳定，参考学习先给出了明确的先验知识，所以整体检测效果很好。但是也能看到系统的一个限制，为了搜索未覆盖区域，后面四个 Planner step 都在确认正常片段，虽然减少了漏检风险，但对这种只有一个明显异常的简单序列来说消耗偏大。

5.2 SMAP 16: 重叠分片检测长异常

SMAP 16 长度为 8473，真实异常从 5225 一直持续到序列末尾 8472，共 3248 个点。系统预测结果为 [4183, 4537] 和 [5837, 8472]。第二个区间覆盖了长异常的大部分，前一个区间则是误报，最终 Point Precision、Recall 和 F1 分别为 0.881、0.812 和 0.845。





图 3: *SMAP 16* 的真实异常与两个最终预测。系统覆盖了异常后 2636 个点，但漏掉起始部分，并在 4183-4537 产生一次误报。


表 3: *SMAP 16* 的关键 *Agent* 轨迹

阶段	Planner 计划	Observation、状态变化与结果
分片	建立 $[0, 6399]$ 与 $[3200, 8472]$ 两个独立任务	两个窗口分别学习正常参考、运行 Planner-Executor。
窗口 0: 概览	Plot(0, 6399)	模型学习到“少量大台阶加长平台”的正常模式。概览发现后半段存在持续上升，候选为 $[5388, 6399]$ ，置信度 0.94；位于真实异常内部。
窗口 0: 局部轨迹	6 个子任务，共 16 个动作	Agent 依次检查 $[5610, 6176]$ 、 $[1400, 1966]$ 、 $[389, 955]$ 、 $[2410, 2976]$ 和 $[3900, 4466]$ 。它先后 Mark 了 $[5610, 6176]$ 、 $[1541, 1543]$ 、 $[745, 746]$ 、 $[2856, 2856]$ 和 $[4183, 4537]$ 。其中第一段命中了真实长异常，但后四段主要来自过拟合的“台阶必须出现在窗口约三分之一处”规则。
窗口 0: Reflection	汇总 5 个候选并复检	Reflection 请求返回的 JSON 解析失败。系统执行 fallback，只保留有两个独立细节证据支持的 $[4183, 4537]$ ；只有一次支持但其实正确的后段趋势候选被删除。窗口 0 因此留下一个误报。
窗口 1: 概览	在局部坐标 Plot(0, 5272)	概览看到局部坐标约 2200 之后持续上升到末尾，判断它违反正常片段“长平台、少量大台阶”的模式。
窗口 1: 连续放大	逐段使用 Plot、Compare 和 Mark	Agent 依次分析局部 $[2200, 2766]$ 、 $[2767, 3452]$ 、 $[3453, 4019]$ 、 $[4020, 4586]$ 和 $[4587, 5272]$ 。每一段都观察到大量小台阶取代长平台，从而把 overview 中的一条长候选拆成多个有细节证据的区间。

阶段	Planner 计划	Observation、状态变化与结果
窗口 1: Reflection	合并相邻候选并重新判断类型	Reflection 认为多个 “frequency” 小段本质上属于一条连续 trend，将边界统一为局部 [2637, 5272]，置信度 0.98。映射回全局后得到 [5837, 8472]。
全局合并 与评估	confidence sum， 阈值 0.5	两个窗口一共输出 [4183, 4537] 和 [5837, 8472]。后者覆盖真实异常的 2636/3248，前者为 355 个误报点。



(a) 第二个窗口的 *overview*。局部坐标约 2200 后不再出现长平台，而是持续上升到末尾。



(b) *Reflection* 检查其中一个局部候选，随后结合另一候选把异常扩展为 [2637, 5272]。

图 4: SMAP 16 第二个分片中的 *overview* 与 *Reflection*。图中坐标是分片局部坐标，需加 3200 才是全局坐标。

分析：这个案例说明长序列分片确实有价值。第一个窗口的 Reflection 发生解析错误，而且 fallback 错误删除了一个真实候选；如果只运行这一个窗口，结果会很差。重叠的第二个窗口从不同上下文再次看到同一长异常，通过连续五个 detail 子任务获得了贯穿到序列末尾的证据，最后 Reflection 把零散小段合并为一条长趋势。换句话说，分片之间的覆盖不只解决了边界切断，还提供了独立重新分析的机会。

该案例也暴露出一些缺陷。第一，正常模式被概括成固定的“台阶位置规则”后，

正常的相位变化容易被误报；第二，系统对 MLLM 输出的格式解析失败会严重影响最终效果。

5.3 SMAP 36：长异常完全漏检

SMAP 36 长度为 8626，真实异常为 [5669, 8625]，占序列约三分之一。系统最终没有输出任何异常区间，四类 F1 都为 0。





图 5: SMAP 36 的完全漏检。真实异常包含尖峰分布变化、基线下降和长时间平坦区，但最终 *prediction* 为空。


表 4: SMAP 36 的关键 Agent 轨迹

阶段	Planner 目标与动作	Observation、状态变化与结果
分片与参考	两个窗口： [0, 6399]、 [3200, 8625]	周期估计得到 2，因此多尺度窗口记为 2、6、10 个点。参考学习把大量短促正尖峰看作正常，并允许很大的幅度变化；使系统更关注单个尖峰。
窗口 0：概览	Plot(0, 6399)	概览提出了四个候选：[335, 337]、[5724, 5726]、[6061, 6065] 和持续抬高的 [6350, 6399]。其中最后一段位于真实异常内，但 Planner 优先选择置信度最高的单个尖峰 [5724, 5726]。
窗口 0：检查失败	尝试 Plot [5722, 5727]	由于最小长度限制，该请求实际对应 focus [5660, 5787]。novelty guard 认为它与已有 focus 重叠并拒绝执行。Executor 随后直接 Finish(goal complete)，没有换一个窗口或改用 Compare。
窗口 0：后续步骤	四次 coverage Plot	[2858, 2863]、[1426, 1431]、[4290, 4295] 和 [710, 715] 全部因同样的重叠判断被拒绝。六个 Planner step 用完后，细节覆盖率仍为 0，四个全局候选没有一个获得细节证据来 Mark。

阶段	Planner 目标与动作	Observation、状态变化与结果
窗口 1: 概览	局部 Plot(0,5425)	模型主要看到大量正常正尖峰，只把局部 [3704,3707] 的负尖峰当作候选，却没有把局部约 2469 之后的整体基线和尖峰分布变化识别为一条长异常。该窗口中真实异常占比很高，使异常形态看起来更像新的背景。
窗口 1: 检查失败	1 次 zoom 加 4 次 coverage	对 [3702,3707]、[1848,1853]、[921,926]、[2775,2780] 和 [4564,4569] 的 Plot 全部被 novelty guard 拒绝。Executor 每次都用 “goal complete” 结束，没有得到任何细节证据。
全局合并	confidence sum	两个窗口都没有预测结果；细节检测覆盖率为 0。最终阶段没有候选可合并，因此最终仍为空。



(a) 窗口 0 的 overview。模型把注意力放在个别高尖峰上，真实长异常只在窗口尾部露出一部分。



(b) 窗口 1 的 overview。局部约 3700 后出现明显的低基线和平坦区，但模型只提出了一个负尖峰候选。

图 6: SMAP 36 两个重叠窗口中 Agent 实际看到的概览图。

分析：长异常覆盖了第二个窗口的大部分后半段。独立分片标准化和局部参考会削

弱“前后分布发生变化”的全局信息，模型于是把异常区间中的尖峰和低基线当成新的局部背景。这个样本示例说明，分片虽然解决了长度问题，但也可能丢失跨窗口的状态变化。

6 代码仓库

https://github.com/isQingyun/HMA-TSAD_Reproduce_KaixuanTian.git

参考文献

- [1] Shunyu Yao, Jeffrey Zhao, Dian Yu, et al. ReAct: Synergizing Reasoning and Acting in Language Models. *International Conference on Learning Representations*, 2023.
- [2] Jiaxin Zhuang, Leon Yan, Zhenwei Zhang, Ruiqi Wang, Jiawei Zhang, and Yuantao Gu. See it, Think it, Sorted: Large Multimodal Models are Few-shot Time Series Anomaly Analyzers. *arXiv preprint arXiv:2411.02465*, 2024.
- [3] Kakam Chong, Musheng Li, and Yuantao Gu. HMA-TSAD: A Hierarchical Multimodal Agent for Time Series Anomaly Detection. Unreleased manuscript, 2026.